爬虫案例1(校花网)

校花网址:http://www.xiaohuar.com/hua/

校花简介信息比如:http://www.xiaohuar.com/p-1-2016.html

一.利用scrapy shell 分析页面:

分析主页中每个标题,链接和下一页

```
[n [5]: le
 Jt [5]:
      <scrapy.linkextractors.lxmlhtml.LxmlLinkExtractor at 0x109cb5048>
In [6]: le = LinkExtractor(restrict_css='div.item_t > div.title > span > a')
In [7]: le
       <scrapy.linkextractors.lxmlhtml.LxmlLinkExtractor at 0x109d55198>
[n [8]: le.extract_links(response)
[Link(url='http://www.xiaohuar.com/p-1-2016.html', text='北京交通大学校花高雅',
fragment='', nofollow=False),
Link(url='http://www.xiaohuar.com/p-1-2015.html', text='吉林大学珠海学院校花余
文丽', fragment='', nofollow=False),
Link(url='http://www.xiaohuar.com/p-1-2010.html', text='聊城大学校花飞儿', fra
ment='', nofollow=False),
Link(url='http://www.xiaohuar.com/p-1-2009.html', text='陕西科技大学校花左宸怡
, fragment='', nofollow=False),
Link(url='http://www.xiaohuar.com/p-1-2007.html', text='韶关市田家炳中学校花邓
雯', fragment='', nofollow=False),
Link(url='http://www.xiaohuar.com/p-1-2005.html', text='鄞州职业高级中学校花翁
川美', fragment='', nofollow=False),
Link(url='http://www.xiaohuar.com/p-1-2004.html', text='河北医科大学校花孙佳萌
```

```
In [14]: sel.css('a::attr(href)').extract_first()
Out[14]: 'http://www.xiaohuar.com/p-1-2016.html'

In [15]: sel.css('a::text').extract_first()
Out[15]: '北京交通大学校花高雅'

In [16]: sel = response.css('div.item_t > div.title > span > a')

In [17]: sel.extract_first()
Out[17]: '<a href="http://www.xiaohuar.com/p-1-2016.html" target="_blank">北京交通大学校花高雅</a>'
```

还有下一页

```
In [21]: sel.css('a::attr(href)').extract_first()
Out[21]: 'http://www.xiaohuar.com/list-1-1.html'
In [22]: sel = response.css('div.page_num a:nth-last-child(2)')
```

```
In [23]: sel = response.css('div.page_num a:nth-last-child(2)')
In [24]: sel.css('a::text').extract_first()
Out[24]: '下一页'
```

注意:要满足前提有下一页

分析详情页面: 详细信息分别为 姓名 学校 空间地址

-----分析完毕

1.构建 catchMM

自动构建了基础类

```
# -*- coding: utf-8 -*-
catch_MM ~/PycharmProjects/catch_MM
                                     i∰port scrapy
atch_MM
 spiders
    🛵 __init__.py
                                     class XiaohuammSpider(scrapy.Spider):
    tiaohuamm.py
                                0
                                         name = 'xiaohuamm
 🛵 __init__.py
                                         allowed_domains = ['www.xiaohuar.com/hua/']
  tems.py
                                         start_urls = ['http://www.xiaohuar.com/hua//']
  🛵 middlewares.py
  a pipelines.py
                                         def parse(self, response):
                             10 0
  a settings.py
```

2.在item中定义好实体类

```
import scrapy

class CatchMmItem(scrapy.Item):
   title = scrapy.Field() # 校花的标题
   mm_name = scrapy.Field() # 校花的名字
   mm_school = scrapy.Field() # 校花所属学校
   mm_zone = scrapy.Field() # 校花的空间
```

3.实现具体的逻辑步骤

```
1 class XiaohuammSpider(scrapy.Spider):
      name = 'xiaohuamm'
      # 注意这里这里用于设置允许被访问的网页地址,一般填充一级域名
      allowed_domains = ['www.xiaohuar.com']
      start urls = ['http://www.xiaohuar.com/hua//']
6
          解析校花的列表页面
8
      def parse(self, response):
9
            提取书籍页面的链接列表
          le = LinkExtractor(restrict_css='div.item_t > div.title > span >a')
10
          # 循环列表,每循环一次就解析一次页面
11
          for link in le.extract_links(response):
12
13
              yield scrapy.Request(link.url,callback=self.parse_mm)
14
          # 循环做完后,提取下一页连接
          le = LinkExtractor(restrict_css='div.page_num a:nth-last-child(2)')
15
16
          links = le.extract_links(response)
17
          if links[0].text == '下一页':
              next_url = links[0].url
18
              yield scrapy.Request(next_url,callback=self.parse)
19
20
21
22
23
      # 解析校花的详细信息页面
24
25
      def parse_mm(self, response):
26
        # 声明实体
27
          mm = CatchMmItem()
28
          # 填充数据
          mm['title'] = response.css('div.div_h1 > h1::text').extract_first()
29
          mm['mm_name'] = response.css('div.infodiv table tr:nth-child(1) td:nth-
   child(2)::text').extract_first()
          mm['mm_school'] = response.css('div.infodiv table tr:nth-child(5) td:nth-
31
  child(2)::text').extract first()
          mm['mm_zone'] = response.css('div.infodiv table tr:nth-child(7) td:nth-child(2)
  a::attr(href)').extract_first()
          yield mm
```

MichaelYun:__Yun\$ cd PycharmProjects/
MichaelYun:PycharmProjects Yun\$ ls

OPP catch_MM example studyPY toscrape_book
MichaelYun:PycharmProjects Yun\$ cd catch_MM/
MichaelYun:catch_MM Yun\$ scrapy crawl xiaohuamm -o MMmsg.csv

执行并输出到 MMmsg.csv

注意: robots.txt 是遵循 Robot协议 的一个文件,它保存在网站的服务器中,它的作用是,告诉搜索引擎爬虫,本网站哪些目录下的网页 不希望 你进行爬取收录。在Scrapy启动后,会在第一时间访问网站的 robots.txt 文件,然后决定该网站的爬取范围。

当然,我们并不是在做搜索引擎,而且在某些情况下我们想要获取的内容恰恰是被 robots.txt 所禁止访问的。所以,某些时候,我们就要将此配置项设置为 False ,拒绝遵守 Robot协议 !

可选项

#指定各项排列顺序 FEED_EXPORT_FIELDS = ['title','mm_name','mm_school','mm_zone']