薰风读论文：ResNeXt 深入解读与模型实现

薰风初入弦
上海交通大学 计算机科学与技术博士在读

已关注

科技猛兽等 70 人赞同了该文章

> 这是薰风读论文的第3篇投稿

薰风说 Thinkings

这篇笔记写的篇幅也许是有史以来最长的了。本来我只想写和ResNet的区别，但学习的过程中发现它和Inception千丝万缕的联系，忍不住扣了扣，回过神来就已经这样了。

很多人认为ResNeXt没什么创新点，因为一来结构照搬Inception；二来，实现只加了个分组卷积，变化微乎其微；因此乏善可陈。

但这反而是ResNeXt的闪光点，只是这闪光点略有些眩目而已。因为若仔细想想，“照搬Inception”必然导致模型复杂，而实现起来却又“变化微乎其微”，这两者之间有巨大的矛盾。

但随着阅读论文/梳理思路/实现模型，再根据模型重新阅读论文梳理思路，进而修改实现这么循环下来，“吃透了”ResNeXt，才发现它的趣味所在。

通过“同构”的简洁，四两拨千斤地击败复杂的Inception，还含蓄地动摇了Inception的出发点。

果然这才是大佬之间的对决吗.jpg

摘要 Abstract

借鉴Inception的“分割-变换-聚合”策略，却用相同的拓扑结构组建ResNeXt模块。
简洁：同构多分枝，因此有更少的超参数
引入“基数”（cardinality），基数增加可提高模型效果。比变深or变宽还好使。

一、引言 Introduction

现在的研究方向已经从早年寻找各类手工设计特征（如SIFT和HOG）的“特征工程”（feature engineering）到寻找高效网络结构的“网络工程”（network engineering）发展。但由于大家设计网络的骚操作五花八门，搞得超参数越来越多，所以现在设计结构也变得越来越难了……

VGG则是个清流，它采用了非常简练的设计原则：堆叠相同形状的模块（blocks）。这种思考方法ResNet用了都说好，只不过ResNet采用相同形状的“残差块”（Residual Blocks）。

这样做不仅满足了广大处女座强迫症患者，最大的好处在于**网络结构有关的超参数只涉及深度和宽度**，那么调参就不用那么疯狂了。

要知道如果超参数太多，调起来麻烦不说，有时候自己都不知道到底哪个参数解决了问题，碰到新问题可能原来调好的模型就又歇逼了。（存在一组过于精细的超参数只对特定数据集有效的风险）。

而VGG同期反其道而行之的Inception，则使用了一套精心设计的网络结构，通过**卷积层之间的稀疏连接**达到了很好的效果。Inception将输入通过1*1conv分到几个低维嵌入。然后用一套特殊的卷积核处理，最后接在一起合成。这就是它特有的**“分割-变换-融合”**策略。

注：稀疏表示指每个block中有几个不同的分支，相互独立互不影响，只在最后把他们的输出拼接在一起（concatenation）。

这么做的好处是，这个Block所能表示的解空间，实际上是一个更大卷积核的严格子空间。但本身复杂度很小。

说人话：Inception用了小卷积核的计算量干了大卷积核的事情，效果还差不多。

Inception的作者认为，Inception的优势更多在于通过精心设计的复杂Block结合多个感受野的特征。但这就正中了一开始分析的下怀：针对问题尽心设计的精巧结构往往会失去足够的泛化性。

那么问题来了，Inception的能力之所以优越，究竟是因为它引以为傲的复杂结构，还是别的什么?

比如，“分割-变换-融合”策略（稀疏连接）？

二、从“分割-变换-融合”到聚合变换

“分割-变换-融合”这技术看起来唬人，但实际上却也一直在我们身边。

1.重新思考神经元

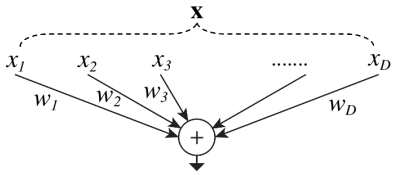

Figure 2. A simple neuron that performs inner product.

普通的内积，普通的神经元

很久很久以前，在CNN还没有大行其道，人们还管全连接层叫神经网络的时候。最常见也是最简单的运算就是输入向量与权重的内积了，而这本来就是一种聚合变换。

$$\sum_{i=1}^{D} w_i x_i$$

其中 $\mathbf{x} = [x_1, x_2, \ldots, x_D]$ 是D通道的输入向量， w_i 则是对应 i 通道的权重。现在我们用之前“分割，变换，聚合”的角度重新描述一下内积过程：

分割：向量 $\mathbf{x}$ 被分成了D个低维嵌入，内积中则被直接分成了一个个1维子空间 x_i
变换：模型对低维表示进行变换，这里只是简单的乘了一个数，变成了 $w_i x_i$
聚合：把全部低维嵌入聚合到一块，这里就是 $\sum_{i=1}^{D}$

2. 聚合变换与NeXt

上面的变换是神经元对输入只进行一次简单内积，现在我们把 $w_i x_i$ 换成更一般的函数，当然这个函数也可以是一个子网络。

也就是说，之前是在一个神经元中的变换从**内积变成了一堆子网络。**

> 如果Inception是“网络中的网络”（Network-in-Network），那么这里就是“神经元中的网络”（Network-in-Neuron）

$$\mathcal{F}(\mathbf{x}) = \sum_{i=1}^{C} \mathcal{T}_i(\mathbf{x})$$

其中 $\mathcal{T}_i$ 是能把 $\mathbf{x}$ 投影到（低维）子空间，并进行变换的任意函数。ResNeXt中，$\mathcal{T}_i$ 是一个自带瓶颈的网络结构（1*1conv降维→3*3conv→1*1conv升维）

C 就是传说中的“基数”了，类比神经元，就和通道数D差不多。论文发现，基数本身可以作为继卷积滤波器宽度（通道数），网络深度（卷积层数）之后的第三个基本超参数（那种理应越大越好的超参数）。特别是当增长深度与宽度对模型的收益边际递减时，基数的增加另辟蹊径解决了这一问题。

> 在深度和宽度外找到了第3个维度：基数。模型也因找到了下一个调参维度，而被称为“NeXt”。

最后，加上我们喜闻乐见的恒等映射，就做好ResNeXt的基本结构啦

$$\mathbf{y} = \mathbf{x} + \sum_{i=1}^{C} T_i(\mathbf{x})$$

2. 为何要强调“聚合变换”？

很多人看到ResNeXt的介绍/论文时，直到这里都是懵的。（以后看到很多人，自动替换成当年的我就好了）

懵了后只想看图，觉得就像作者吹了半天牛，其实只是把Inception的idea直接照抄过来。

其实不然，作者写这么多非但不是为了把Inception的想法照抄，**而是想把Inception从立脚点开始到性能都吊起来打一顿。**

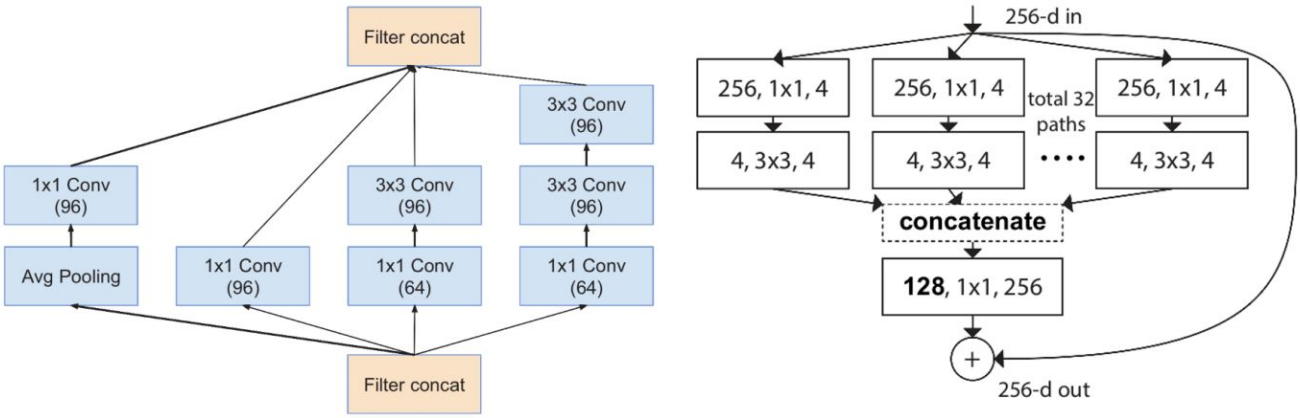

左边是Inception，右边是ResNext

观察两个Block结构，能发现二者有何差别？（除了上下颠倒，除了一个彩色一个黑白……）

最本质的差别，其实是Block内每个分支的拓扑结构，Inception为了提高表达能力/结合不同感受野，每个分支使用了不同的拓扑结构。

而ResNeXt则使用了同一拓扑的分支，即ResNeXt的**分支是同构的！**

分支是同构的！

分支是同构的！

同构的分支才是问题所在，它从根本上动摇了一个独步江湖几年的经典模型的根基。

三、 “同构”

因为ResNeXt是同构的，因此继承了VGG/ResNet的精神衣钵：维持网络拓扑结构不变。主要体现在两点：

特征图大小相同，则涉及的结构超参数相同
每当空间分辨率/2（降采样），则卷积核的宽度*2（我在Res中写作深度，但还是宽度比较严谨，

避免和层数的“深度”产生歧义）。

只不过，ResNeXt通过分析得出的 $\mathcal{T}_i$ ，拓展了VGG设计原则：从重复相同大小的层，到重复相同拓扑的滤波器组。

除了更加简洁的设计语言，更简单的调参过程，成品模型迁移中更强的鲁棒性外，同构网络在实现时也很有优势。

1.“过于简单的”实现

现在已经有了无数人的结论，以及很多优秀的开源代码，仔细观察这些“成品”，不难发现ResNeXt的实现意外地简洁，至少远比Inception简洁。

简洁到只要给ResNet加个参数，两个卷积换成3个卷积，每个Block里的3*3conv换成分组卷积就好了。

如下代码快所示，比较需要注意的就是第8行中的 groups=cardinality

```
class ResNeXtBottleneck(nn.Module):
 def __init__(self, in_channels, out_channels, stride, cardinality, base_width, widen_
 super(ResNeXtBottleneck, self).__init__()
        width_ratio = out_channels / (widen_factor * 64.)
        D = cardinality * int(base_width * width_ratio)
        self.conv_reduce = nn.Conv2d(in_channels, D, kernel_size=1, stride=1, padding=
        self.bn_reduce = nn.BatchNorm2d(D)
        self.conv_conv = nn.Conv2d(D, D, kernel_size=3, stride=stride, padding=1, grou
        self.bn = nn.BatchNorm2d(D)
        self.conv_expand = nn.Conv2d(D, out_channels, kernel_size=1, stride=1, padding
        self.bn_expand = nn.BatchNorm2d(out_channels)

        self.shortcut = nn.Sequential()
 if in_channels != out_channels:
            self.shortcut.add_module('shortcut_conv',
                                     nn.Conv2d(in_channels, out_channels, kernel_size=
                                               bias=False))
            self.shortcut.add_module('shortcut_bn', nn.BatchNorm2d(out_channels))
```

但，这推导到现在的结构比起来，是不是太简单了点?

2. 同构ResNeXt Block的等价形式

在引入等价形式之前，我们再看一看推导聚合变换时的式子

$$\mathcal{F}(\mathbf{x}) = \sum_{i=1}^{C} \mathcal{T}_i(\mathbf{x})$$

还有内积时的式子

$$\mathcal{F}(\mathbf{x}) = \sum_{i=1}^{D} w_i x_i$$

不知到大家看出什么不同了吗？在于右边式子的自变量。通项公式中写的是向量 $\mathbf{x}$ ，但内积中求和的却是向量 $\mathbf{x}$ 其中一个通道 x_i 。

而论文中也明确指出 $\mathcal{T}_i$ ， 的作用是： “**先把输入分发到（低维）嵌入中**，再对第i个嵌入变换”，最后对基数C个变换进行汇总。根据这种最开始的想法，我们能得到第一个ResNeXt Block的结构示意图：

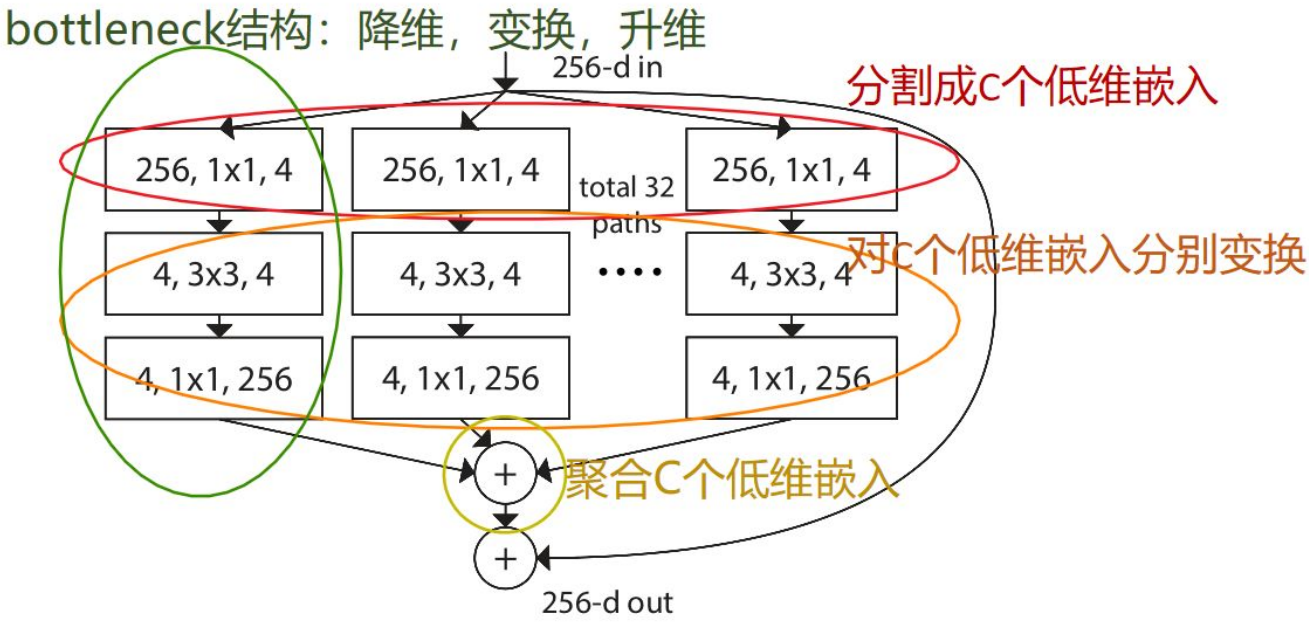

ResNeXt Block结构示意图 V1.0

也就是说，如果只看每个Block中单独的支路（Branch），则其只是一个常见的“降维→变换→升维”的Bottleneck结构。但是，若以“分割-变换-聚合”的角度考虑，那么第一个1*1conv的“降维”，实际上也是把输入分给基数（这里C=32）个低维嵌入的过程。

而在内积中，第一个分割成低维嵌入的过程实际上只是挨个取元素，所以被我们直观忽略了。

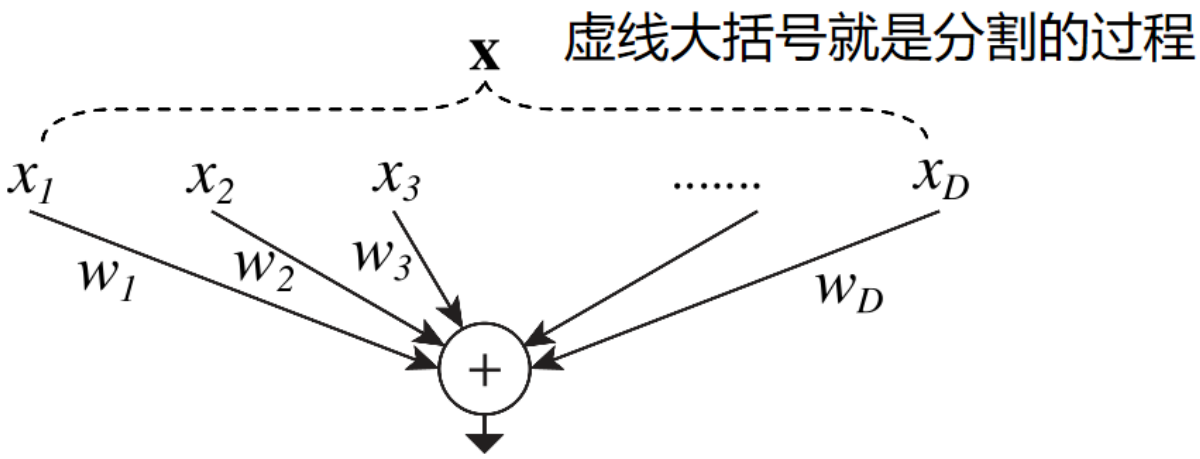

OK，罗嗦这个意义何在？

意义在于让我们知道，分割/汇聚不一定是个显式过程，必要时完全可以等加成更简单的表达。就好比Inception-ResNet形式表示的ResNeXt Block：

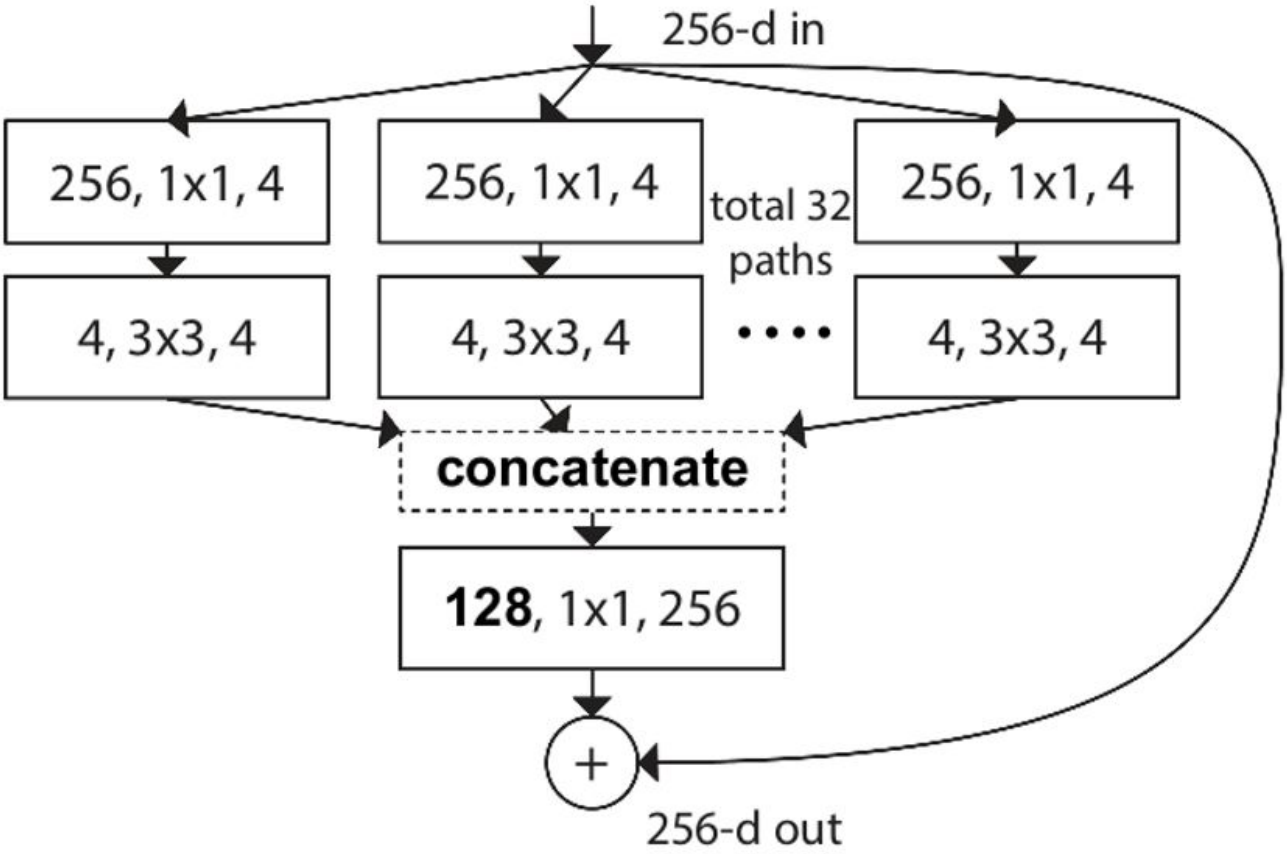

ResNeXt Block结构示意图 V2.0

32个输入4通道，输出256通道的1*1conv加起来，和32个4通道拼在一起变成128通道，再过一个输入128通道输出256通道的1*1conv有多大区别呢？

我们用MobileNet中计算标准卷积参数量的公式来计算：

$$D_K \cdot D_K \cdot M \cdot N$$

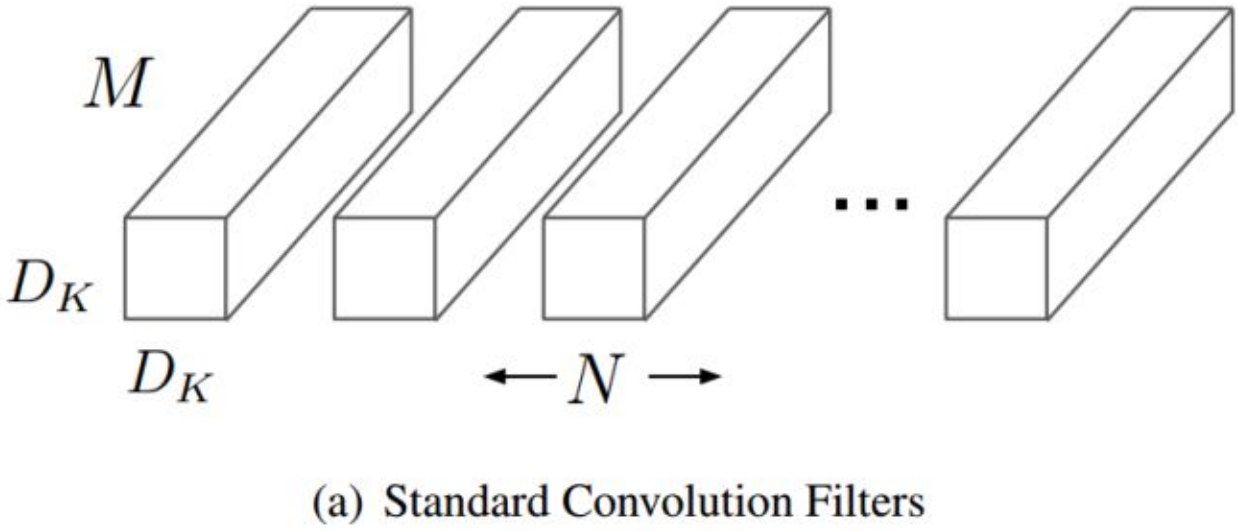

MobileNet中当靶子打的标准卷积

从参数量上：前者为32*（1*1*4*256）=32768

后者为1*1*128*256=32768

显然，两者的参数量一样。而Inception早已说明了Block所能表示的解空间，实际上是一个更大卷积核的严格子空间。也就是说，先汇聚后一个大的标准卷积，能表达的范围只会比一堆小的标准卷积之组合更大。因此，这种后者对前者的等价没问题。

那么同理，在最后的32个conv能用上述方法等效成大的conv，那最前面的conv也同理可得一个等效的大conv。那么类似于我在ResNet中提到的滑稽情况（若ResNet的恒等映射中间只有一层权重时，恒等映射加了等于没加）又出现了：

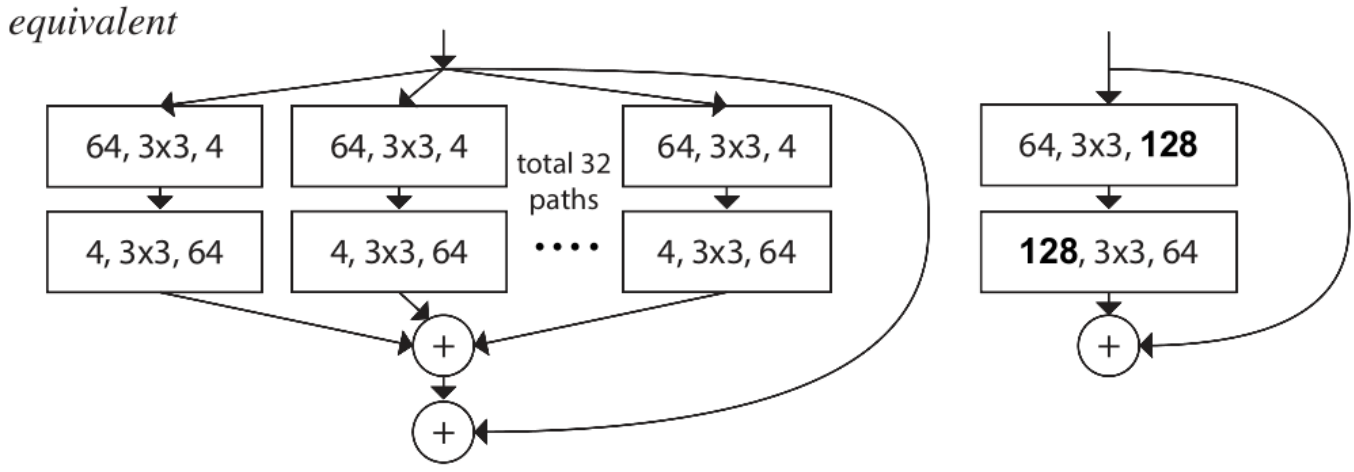

ResNeXt Block结构示意图 V2.50

如上图所示，如果一个ResNeXt Block中只有两层conv，前后都可等效成一个大的conv层，那聚合变换和没聚一样。

> **如果看到这里，你已经完成了对这么个看似很“Inception”，看似很“高大上”的模型祛魅的过程。**

因为这种反面例子同样告诉了我们，抛弃重重理论，ResNeXt**最核心的地方只存在于被最上最下两层卷积夹着的，中间的部分。**和汉堡一样，两边都是面包，中间的肉最值钱。

为什么呢，因为第一个分开的conv其实都接受了一样的输入，各分支又有着相同的拓扑结构。类比乘法结合律，这其实就是把一个conv的输出拆开了分掉。（**相同输入，不同输出）**

而最后一个conv又只对同一个输出负责，因此就可以并起来用一个conv处理。（**不同输入，相同输出**）

唯一一个输入和输出都不同的，就是中间的3*3conv了。它们的输入，参数，负责的输出都不同，无法合并，因此也相互独立。这才是模型的关键所在。最终模型可以被等效为下图所示的最终形态：

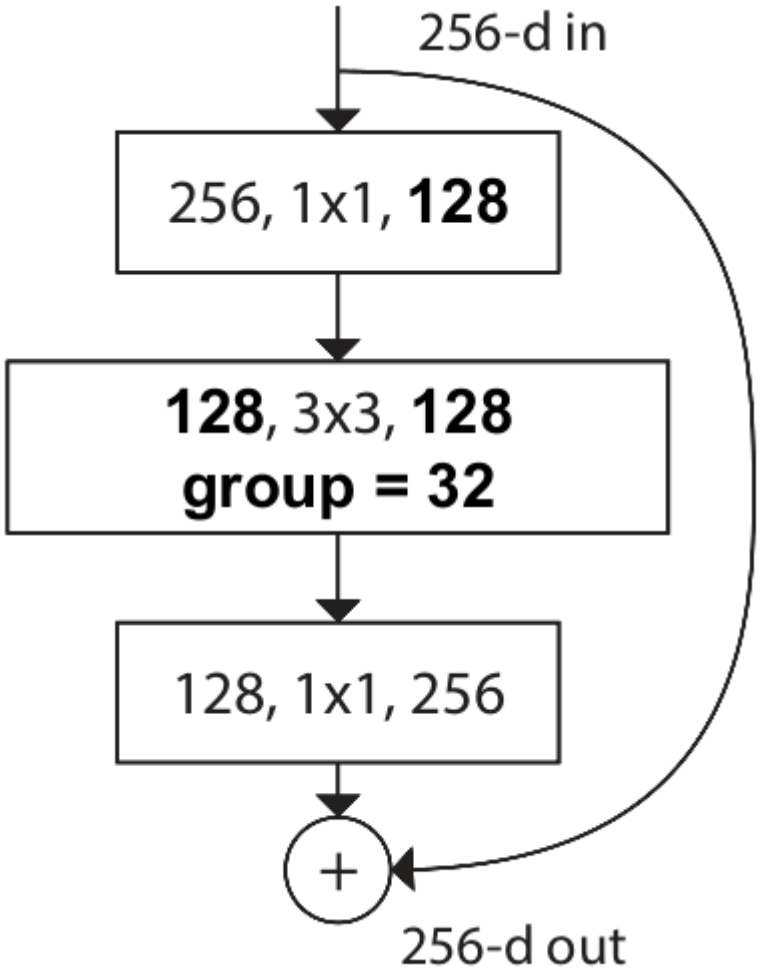

ResNeXt Block结构示意图 V3

而很巧的是，AlexNet的**分组卷积实际上干了一样的事。**只不过Alex当时这么做是形势所逼。ResNeXt却是主动选择，还成为了提高模型效果的手段。

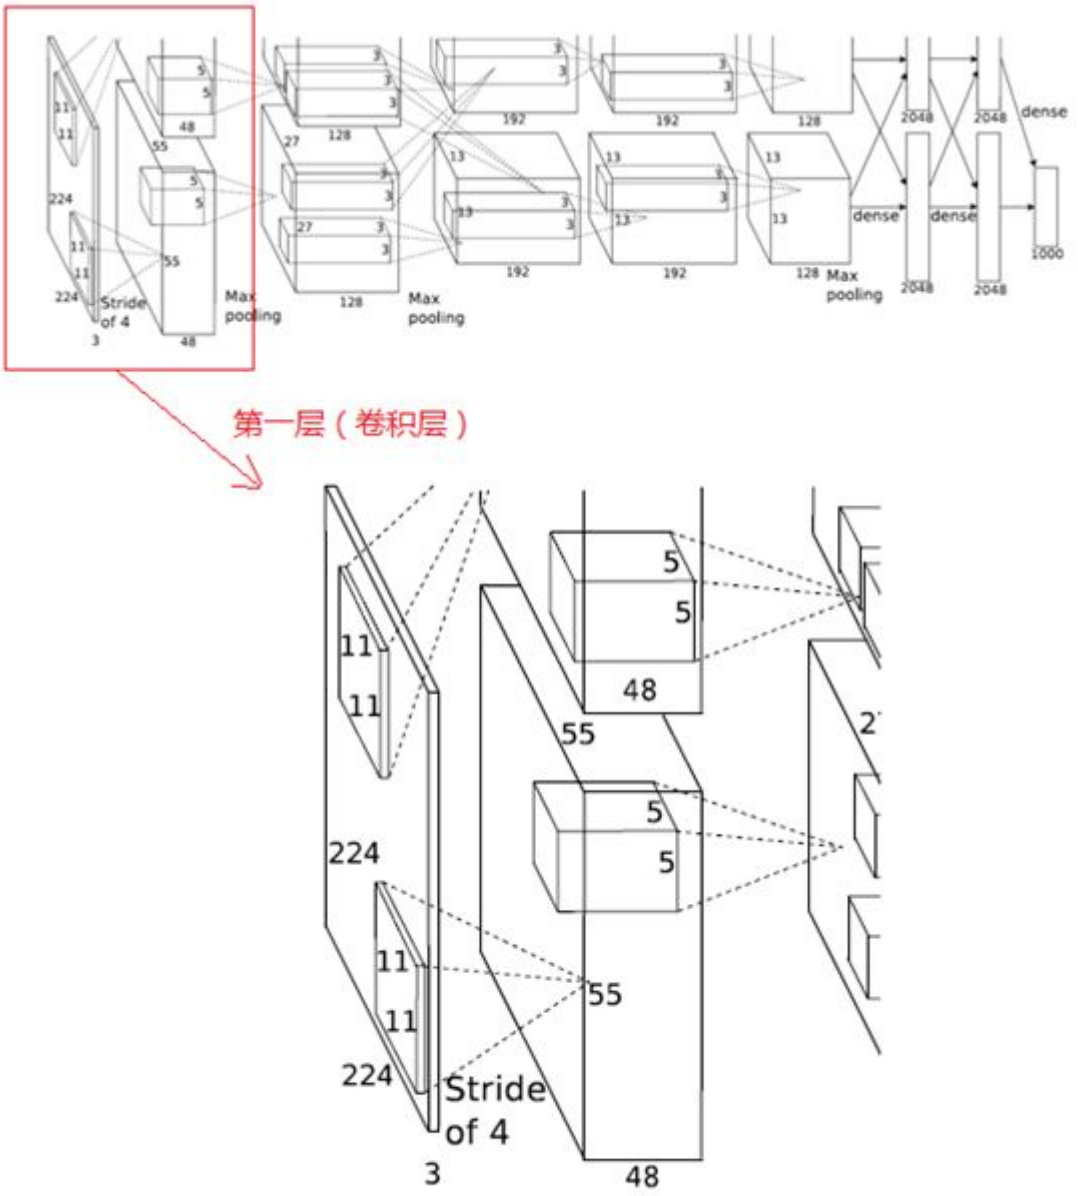

当年Alex第一层卷积的迫不得已

到这里，同构更大的优势就体现出来了：**因为同构，所以经过层层等价，ResNeXt的模型远比Inception来的简洁优雅，易于实现。**

四、模型容量 被遗忘的d

到这里，模型的亮点和特色也差不多了。但是，很多博文都会遗忘掉模型中的另外一个超参数D

```
self.conv_conv = nn.Conv2d(D, D, kernel_size=3, stride=stride, padding=1, groups=cardi
```

就是这段代码的D（论文里为d），它指代C个分支的bottleneck中，降维得到低维嵌入的维度。因此，我们得到最终一个ResNeXt模块的参数量：

$$C \cdot (\text{Inchannel} \cdot d + 3 \cdot 3 \cdot d \cdot d + d \cdot \text{Outchannel})$$

可以看出，若d的取值足够小，则模型本身相较ResNet的参数量也不会很大。这就是论文所说的，在保证计算复杂性不变的同时，取得更优结果。